

《回归模型与方差分析》2026 · Assignment 1

完全解答

说明：本解答包含每题完整的推导（题 1 - 4）与数据分析结果（题 5 - 8）。所有数值结果与图都可由本目录下的代码一键复现：

```
bash code/run_all.sh # 依次运行 6 个脚本
```

数据文件在 data/，生成的表格在 results/，图像在 figures/。模拟与数值校核（恒等式检查、Monte Carlo、全子集穷举）在 code/p1_p4_verify.py 和 code/p8_student.py 中，用于确认代数推导的每一条结论。

答案速览

题号	结论	关键数值
1	$\sum \hat{y}_i / n = \bar{y}$; $SS_{\text{reg}} = \sum (\hat{y}_i - \bar{y})^2 = \hat{\beta}_1^2 S_{xx}$; $R^2 = r_{XY}^2$	数值残差 $\leq 10^{-12}$
2	两者都无偏; $\text{Var}(\hat{\beta}) \leq \text{Var}(\tilde{\beta})$, 等号仅当所有 x_i 相同	方差比 $0.9449 = n\bar{x}^2 / \sum x_i^2$
3	$\tilde{\beta}_1 = (X_1^\top X_1)^{-1} X_1^\top Y$; 无偏 $\iff X_1^\top X_2 = 0$	有偏 0.650, 正交 9×10^{-17}
4	$\hat{b} = (Z^\top Z)^{-1} Z^\top Y$, 前 $p+1$ 个分量无偏 $E[\tilde{\beta}] = \beta^*$	偏差 ≤ 0.007 , 方差膨胀至 2.85 倍
5	三种样条明显优于三次多项式; 自然样条 ($K=10$) 与三次样条 ($K=7$) 最好	L00CV 2.851×10^6 vs 2.957×10^6
6	前三个主成分累计解释 72.5% 的方差; gdp 回归 $R^2 = 0.6908$	$F = 13.40$, $p = 7.7 \times 10^{-5}$
7	R_{adj}^2 选 $Y \sim A + B + C$; AIC、BIC 选只有截距的 $Y \sim 1$	嵌套 F 检验均不显著 ($p \geq 0.20$)
8	FS / BE / FS+BE 在 AIC 与 BIC 下都选中全部 5 个自变量	$R^2 = 0.9888$, 与全子集穷举最优一致

Problem 1 (15 pts)

设 $\hat{\beta}_0, \hat{\beta}_1$ 为简单线性回归 $y_i = \beta_0 + \beta_1 x_i + e_i$ 的最小二乘估计, $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$, 并记 $\bar{x} = \frac{1}{n} \sum x_i$ 、 $\bar{y} = \frac{1}{n} \sum y_i$, $S_{xx} = \sum (x_i - \bar{x})^2$ 、 $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ 、 $S_{yy} = \sum (y_i - \bar{y})^2$ 。

最小二乘的正规方程 (normal equations) 为

$$\sum_{i=1}^n (y_i - \hat{y}_i) = 0, \quad \sum_{i=1}^n x_i (y_i - \hat{y}_i) = 0.$$

记残差 $e_i = y_i - \hat{y}_i$, 即 $\sum e_i = 0$, $\sum x_i e_i = 0$ 。这两个等式是所有结论的来源。

(1) $\frac{1}{n} \sum_{i=1}^n \hat{y}_i = \bar{y}$

由正规方程第一式 $\sum e_i = 0$,

$$\sum_{i=1}^n \hat{y}_i = \sum_{i=1}^n (y_i - e_i) = \sum_{i=1}^n y_i - \sum_{i=1}^n e_i = \sum_{i=1}^n y_i,$$

两边除以 n 即得 $\frac{1}{n} \sum \hat{y}_i = \bar{y}$ 。也就是说：回归直线必过样本重心 $(\bar{x}, \bar{y})$ （等价地 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$, 这与 $\hat{\beta}_1 = S_{xy}/S_{xx}$ 的公式一致）。值得注意的是，结论只需要 $\sum e_i = 0$, 不需要任何分布假设。

$$(2) SS_{\text{reg}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

这里 SS_{reg} (回归平方和) 按定义就是 $\sum_i (\hat{y}_i - \bar{y})^2$ 。为完整起见, 我们证明若干等价的常用表达式, 以及相应的平方和分解。

引理 (平方和分解): $S_{yy} = \sum_i (\hat{y}_i - \bar{y})^2 + \sum_i (y_i - \hat{y}_i)^2$ 。

证明: 先展开

$$\sum_i (y_i - \bar{y})^2 = \sum_i [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 = \sum_i e_i^2 + 2 \sum_i e_i (\hat{y}_i - \bar{y}) + \sum_i (\hat{y}_i - \bar{y})^2.$$

交叉项为零, 因为 $\hat{y}_i - \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 x_i - (\hat{\beta}_0 + \hat{\beta}_1 \bar{x}) = \hat{\beta}_1 (x_i - \bar{x})$, 于是由正规方程

$$\sum_i e_i (\hat{y}_i - \bar{y}) = \hat{\beta}_1 \left[\sum_i x_i e_i - \bar{x} \sum_i e_i \right] = 0.$$

故 $S_{yy} = SSE + SS_{\text{reg}}$, 其中 $SSE = \sum_i e_i^2$ 。■

再由 $\hat{y}_i - \bar{y} = \hat{\beta}_1 (x_i - \bar{x})$ 立得

$$SS_{\text{reg}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \hat{\beta}_1^2 S_{xx} = \frac{S_{xy}^2}{S_{xx}}.$$

又由 (1) 有 $\sum_i \hat{y}_i = n\bar{y}$, 所以

$$SS_{\text{reg}} = \sum_i \hat{y}_i^2 - 2\bar{y} \sum_i \hat{y}_i + n\bar{y}^2 = \sum_i \hat{y}_i^2 - n\bar{y}^2.$$

综上:

$$SS_{\text{reg}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \hat{\beta}_1^2 S_{xx} = \frac{S_{xy}^2}{S_{xx}} = \sum_{i=1}^n \hat{y}_i^2 - n\bar{y}^2, \quad S_{yy} = SS_{\text{reg}} + SSE.$$

$$(3) R^2 = r_{XY}^2$$

按定义 $R^2 = SS_{\text{reg}}/S_{yy}$ (一般模型的 $R^2 = 1 - SSE/SST$, 在这里 $SST = S_{yy}$, 由 (2) 两者一致)。把上面的表达式代入:

$$R^2 = \frac{SS_{\text{reg}}}{S_{yy}} = \frac{S_{xy}^2/S_{xx}}{S_{yy}} = \frac{S_{xy}^2}{S_{xx}S_{yy}} = r_{XY}^2,$$

其中 r_{XY} 是 X 与 Y 的样本相关系数。由 Cauchy - Schwarz 不等式 $S_{xy}^2 \leq S_{xx}S_{yy}$ 立刻得到 $0 \leq R^2 \leq 1$, 并且 $R^2 = 1$ 当且仅当所有点共线 ($e_i \equiv 0$)。

数值复核 (code/p1_p4_verify.py, $n = 37$): 三条恒等式的数值残差分别为 $|\frac{1}{n} \sum_i \hat{y}_i - \bar{y}| = 3.6 \times 10^{-15}$ 、 $|SS_{\text{reg}} - \hat{\beta}_1^2 S_{xx}| = 3.4 \times 10^{-13}$ 、 $|R^2 - r_{XY}^2| = 4.4 \times 10^{-16}$ 、 $|S_{yy} - SS_{\text{reg}} - SSE| = 3.8 \times 10^{-13}$, 与理论完全一致。

Problem 2 (10 pts)

模型 $y_i = \beta^* x_i + e_i$, e_i 独立同分布 $N(0, \sigma_*^2)$, 不含截距。

(1) 两个估计量都无偏

在无截距模型下最小二乘问题为 $\min_{\beta} \sum_i (y_i - \beta x_i)^2$ ，其驻点满足 $\sum_i x_i (y_i - \beta x_i) = 0$ ，即

$$\hat{\beta} = \frac{\sum_i x_i y_i}{\sum_i x_i^2}.$$

(假设 $\sum_i x_i^2 > 0$ 。) 由 $\mathbb{E}[y_i] = \beta^* x_i$,

$$\mathbb{E}[\hat{\beta}] = \frac{\sum_i x_i \mathbb{E}[y_i]}{\sum_i x_i^2} = \beta^* \frac{\sum_i x_i^2}{\sum_i x_i^2} = \beta^*.$$

另一个估计量 $\tilde{\beta} = \bar{y}/\bar{x}$ (假设 $\bar{x} \neq 0$) 满足

$$\mathbb{E}[\tilde{\beta}] = \frac{\mathbb{E}[\bar{y}]}{\bar{x}} = \frac{\beta^* \bar{x}}{\bar{x}} = \beta^*.$$

故两者都是 β^* 的无偏估计。注意：无偏性只用到 $\mathbb{E}[e_i] = 0$ ，不需要正态性（正态性只在做区间估计、检验或比较分布时才会用到）。

(2) 方差比较： $\hat{\beta}$ 的方差更小

由 e_i 独立、 $\text{Var}(e_i) = \sigma_*^2$ ：

$$\text{Var}(\hat{\beta}) = \frac{\sum_i x_i^2 \text{Var}(y_i)}{(\sum_i x_i^2)^2} = \frac{\sigma_*^2}{\sum_i x_i^2}, \quad \text{Var}(\tilde{\beta}) = \frac{\text{Var}(\bar{y})}{\bar{x}^2} = \frac{n\sigma_*^2/n^2}{\bar{x}^2} = \frac{\sigma_*^2}{n\bar{x}^2}.$$

关键恒等式是平方和分解

$$\sum_{i=1}^n x_i^2 = n\bar{x}^2 + \sum_{i=1}^n (x_i - \bar{x})^2 \geq n\bar{x}^2,$$

等号成立当且仅当 $x_1 = \dots = x_n = \bar{x}$ 。于是

$$\text{Var}(\hat{\beta}) = \frac{\sigma_*^2}{\sum_i x_i^2} \leq \frac{\sigma_*^2}{n\bar{x}^2} = \text{Var}(\tilde{\beta}), \quad \frac{\text{Var}(\tilde{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sum_i x_i^2}{n\bar{x}^2} = 1 + \frac{\sum_i (x_i - \bar{x})^2}{n\bar{x}^2} \geq 1.$$

结论：除非所有 x_i 完全相同（此时 $S_{xx} = 0$ 、两估计量重合）， $\hat{\beta}$ 的方差严格小于 $\tilde{\beta}$ 的方差，因此 $\hat{\beta}$ 更优（事实上它是该无截距模型下的 BLUE，也是 β 的极大似然估计）。直观上， $\tilde{\beta}$ 只用到了 y 的均值而完全丢弃了 x_i 与 y_i 的配对信息，只要 x 有波动（ $S_{xx} > 0$ ）就浪费了信息；比值 $1 + S_{xx}/(n\bar{x}^2)$ 也说明 x 的相对波动越大， $\hat{\beta}$ 的优势越明显。

数值复核（ $n = 12$ ， $\beta^* = 2$ ， 10^5 次模拟）： $\mathbb{E}[\hat{\beta}] = 1.99985$ 、 $\mathbb{E}[\tilde{\beta}] = 1.99986$ （均与 β^* 无显著差异）；理论方差 $\text{Var}(\hat{\beta}) = \sigma^2/\sum_i x_i^2 = 0.005885$ ， $\text{Var}(\tilde{\beta}) = \sigma^2/(n\bar{x}^2) = 0.006228$ ，模拟值 0.005914 与 0.006257 与之吻合；方差比 0.9449 与 $n\bar{x}^2/\sum_i x_i^2$ 精确一致。

Problem 3 (10 pts)：欠拟合与遗漏变量偏差

真实模型 $Y = X\beta^* + e = X_1\beta_1^* + X_2\beta_2^* + e$ ，但我们只把前 p_1 列 X_1 放进回归。

(1) 遗漏变量模型的估计量

最小二乘问题 $\min_{\beta_1} \|Y - X_1\beta_1\|^2$ 的正规方程为 $X_1^\top X_1\beta_1 = X_1^\top Y$ ，当 X_1 列满秩（ $\text{rank}(X_1) = p_1$ ，即 $X_1^\top X_1$ 可逆）时

$$\tilde{\beta}_1 = (X_1^\top X_1)^{-1} X_1^\top Y.$$

(2) 无偏 $\iff X_1^\top X_2 = 0$

把真实模型代入上式并取期望 ($E[e] = 0$, $\times$ 非随机) :

$$E[\tilde{\beta}_1] = (X_1^\top X_1)^{-1} X_1^\top (X_1 \beta_1^* + X_2 \beta_2^*) = \beta_1^* + A \beta_2^*, \quad A := (X_1^\top X_1)^{-1} X_1^\top X_2.$$

充分性: 若 $X_1^\top X_2 = 0$ 则 $A = 0$, 于是 $E[\tilde{\beta}_1] = \beta_1^*$ 。

必要性: 若 $\tilde{\beta}_1$ 是 β_1^* 的无偏估计 (即对任意真参数 β^* 、特别对任意 β_2^* 都有 $E[\tilde{\beta}_1] = \beta_1^*$) ,

则必须 $A \beta_2^* = 0$ 对一切 $\beta_2^* \in \mathbb{R}^{p_2}$ 成立, 即 $A = 0$ 。再用 $X_1^\top X_1$ 可逆: $A = (X_1^\top X_1)^{-1} X_1^\top X_2 = 0 \iff X_1^\top X_2 = 0$ 。

。 ■

注记 (本题最重要的两点)

1. $A \beta_2^*$ 就是经典的遗漏变量偏差 (omitted-variable bias)。它为零的两种情形是:

$X_1^\top X_2 = 0$ (新老变量正交), 或者被漏掉的系数恰好为 0 ($\beta_2^* = 0$, 即“漏掉”的其实是无关变量)。

2. 由于 X_1 的第一列是全为 1 的常数列, $X_1^\top X_2 = 0$ 还要求 X_2 的每一列样本均值为 0

(因为 $X_1^\top X_2$ 的第一行是 $1^\top X_2$)。所以只要漏掉的变量在样本中均值非零, 截距项就会“吸收”它们的一部分影响, 估计量就有偏。

数值复核: 取 $n = 60$, $X_1 = [1, x]$, X_2 为两个随机变量, $\beta_2^* = (3, -1.5)$ 。一般情形下偏差 $A \beta_2^*$ 的最大分量为 0.650 (而 $\max |X_1^\top X_2| = 12.87$) ; 构造与 X_1 正交的 X_2 后偏差为 8.8×10^{-17} , 与理论相符。

Problem 4 (10 pts): 过拟合与无关变量

真实模型 $Y = X \beta^* + e$, 我们额外加入 q 列 X' , 令 $Z = [X \ X']$, 并把真系数补零写成 $b^* = (\beta^{*\top}, 0, \dots, 0)^\top$, 于是同样有 $Y = Z b^* + e$ 。

(1) 过拟合模型的估计量

$\min_b \|Y - Zb\|^2$ 的正规方程为 $Z^\top Z b = Z^\top Y$, 若 Z 列满秩则

$$\hat{b} = (Z^\top Z)^{-1} Z^\top Y.$$

(2) 前 $p+1$ 个分量无偏

$$E[\hat{b}] = (Z^\top Z)^{-1} Z^\top E[Y] = (Z^\top Z)^{-1} Z^\top Z b^* = b^* = \begin{pmatrix} \beta^* \\ 0 \end{pmatrix}.$$

取前 $p+1$ 个分量即得 $E[\tilde{\beta}] = \beta^*$ 。结论: 加入了无关变量后, 参数估计仍然无偏 (同时附加的 q 个系数也以 0 为无偏目标)。 ■

注记: 无偏的代价是方差膨胀。 写

$$Z^\top Z = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}, \quad A_{11} = X^\top X, \quad A_{12} = X^\top X' = A_{21}^\top, \quad A_{22} = X'^\top X',$$

利用分块矩阵求逆公式， $\text{Cov}(\hat{\mathbf{b}}) = \sigma^2(\mathbf{Z}^\top \mathbf{Z})^{-1}$ 的左上 $(p+1) \times (p+1)$ 块是

$$\text{Cov}(\tilde{\beta}) = \sigma^2[(\mathbf{X}^\top \mathbf{X})^{-1} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}' [\mathbf{X}'^\top (\mathbf{I} - \mathbf{P}_X) \mathbf{X}']^{-1} \mathbf{X}'^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}],$$

其中 $\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 。第二项是半正定的，因此

$$\text{Cov}(\tilde{\beta}) \geq \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1} = \text{Cov}(\hat{\beta}_{\text{true}}),$$

等号成立当且仅当 $\mathbf{X}^\top \mathbf{X}' = 0$ （无关变量与原有变量样本正交）。单变量的形式就是我们熟悉的方差膨胀因子：

$$\text{Var}(\tilde{\beta}_j) = \frac{\sigma^2}{(n-1)s_{x_j}^2} \cdot \text{VIF}_j, \quad \text{VIF}_j = \frac{1}{1-R_j^2},$$

其中 R_j^2 是第 j 个自变量对其余所有自变量（含无关变量）回归的 R^2 。

数值复核（ $n=80$, $p=3$, $q=2$, 4000 次模拟）：

情形	真实系数偏差	方差膨胀倍数 (MC)
无关变量与 $\mathbf{X}$ 独立	0.0034	1.006
无关变量与 $\mathbf{X}$ 强相关 (VIF = 3.57, 2.71)	0.0066	2.81, 2.71

两点观察与理论一致：(i) 两种情形下前 $p+1$ 个系数的模拟均值都接近真值（无偏）；(ii) 当无关变量与原有变量几乎正交时几乎不产生方差膨胀，而在强相关时方差可以膨胀近 3 倍。

补充：加入无关变量也不改变拟合值的期望（ $\mathbf{P}_Z \mathbf{X} = \mathbf{X}$ ，故 $\mathbb{E}[\hat{\mathbf{y}}] = \mathbf{X}\beta^*$ 与真模型相同），但拟合值的方差同样增大：模拟中 $\text{Var}(\hat{\mathbf{y}}_{\text{overfit}})/\text{Var}(\hat{\mathbf{y}}_{\text{true}})$ 的最大值达到 6.6（对应杠杆最大的样本点）。这正是“过拟合”的量化表现：无偏不等于更准，MSE 会更差（ $\text{MSE} = \text{bias}^2 + \text{variance}$ ，偏差为 0 而方差变大）。

Problem 5 (20 pts)：用电量的四种曲线拟合

5.1 数据与模型设定

powerconsumption.csv 记录 2017 年摩洛哥三个地区每天的用电量（ $n=364$, 2017-01-01 至 2017-12-30）。我们取 $Y = \text{PowerConsumption_Zone1}$ （当日各区用电量）， $x = \text{Temperature}$ （当日温度， $^\circ\text{C}$ ）。数据范围： $x \in [8.63, 32.43]$, $Y \in [26772, 38733]$ 。四个模型均为线性参数模型，可以统一写成 $Y = \Psi(x)^\top \theta + \varepsilon$ 并用最小二乘拟合：

(a) 三次多项式： $\Psi(x) = (1, x, x^2, x^3)^\top$ ，参数个数 4。

(b) 三次样条（以 $\xi_1 < \dots < \xi_K$ 为结点，截断幂基）： $\Psi(x) = (1, x, x^2, x^3, (x - \xi_1)_+^3, \dots, (x - \xi_K)_+^3)^\top$ ，参数个数 $K+4$ 。

(c) 自然三次样条（ K 个结点的 K 维基，见 Hastie 等《统计学习基础》§5.2.1）：

$$\Psi(x) = (1, x, d_1(x), \dots, d_{K-2}(x))^\top, \quad d_j(x) = \frac{(x - \xi_j)_+^3 - (x - \xi_K)_+^3}{\xi_K - \xi_j},$$

参数个数 K ；它在边界外是线性的（二阶导数在 ξ_1, ξ_K 外为零），比普通三次样条更稳定。

(d) 平滑样条：以全部观测点为结点的自然三次平滑样条，极小化

$$\sum_i (y_i - f(x_i))^2 + \lambda \int f''(t)^2 dt.$$


对结点集 N ($N_{ij} = d_j(x_i)$) 记 $\Omega_{jk} = \int d_j''(t) d_k''(t) dt$ (用 Gauss - Legendre 分段精确积分), 则 $\hat{f} = \sum \hat{\theta}_j d_j$, $\hat{\theta} = (N^T N + \lambda \Omega)^{-1} N^T y$, 光滑参数 λ 由广义交叉验证 (GCV) 选取, 自由度 $edf = \text{tr}[N(N^T N + \lambda \Omega)^{-1} N^T]$ 。

结点选择: 三次样条与自然样条的结点个数 K 用留一交叉验证 (LOOCV) 在 $K = 2, \dots, 14$ 上选取, 并同时报告 AIC/BIC 的选择作为稳健性对照 ($K = 2$ 时三次样条退化为三次多项式)。在等距分位点结点下, K 越大模型越灵活, RSS 单调下降但方差上升, 故需要用准则权衡。


5.2 结果

结点选择: 三次样条 LOOCV 选 $K = 7$ (AIC 也选 7, BIC 选 2); 自然样条 LOOCV 与 AIC 都选 $K = 10$ (BIC 选 4); 平滑样条由 GCV 选出 $\lambda = 21.14$, 对应 $edf = 8.35$ 。把各准则选出的模型一并列出 (k 为有效参数个数):

模型	k	RSS	R ²	R ² adj	AIC	BIC	LOOCV
自然三次样条 K=10	10	9.8676e+08	0.6185	0.6088	5411.85	5450.82	2.8513e+06
三次样条 K=7	11	9.8613e+08	0.6187	0.6079	5413.62	5456.49	2.8573e+06
平滑样条 (edf=8.35)	8.35	9.9645e+08	0.6148	0.6068	5412.10	5444.63	2.8654e+06
自然样条 K=4 (BIC 选择)	4	1.0290e+09	0.6022	0.5989	5415.11	5430.70	2.8851e+06
三次样条 K=2 (BIC 选择)	6	1.0190e+09	0.6060	0.6005	5415.55	5438.93	2.9081e+06
三次多项式	4	1.0528e+09	0.5930	0.5896	5423.45	5439.03	2.9565e+06



四种拟合曲线的比较 (同一张图)



分面展示：每个模型的拟合与评价指标

5.3 讨论

1. 排序：按 LOOCV（预测误差）与 AIC，自然三次样条（ $K=10$ ）最好，三次样条（ $K=7$ ）紧随其后，

平滑样条（ $edf=8.35$ ）与它们几乎等价（差别在 0.5% 以内），三次多项式最差：其 RSS 比最好的样条高约 6.7%，LOOCV 高约 3.7%。也就是说，仅用 4 个参数的全局三次多项式无法刻画这条曲线在 $12-15^\circ\text{C}$ 与 $20-24^\circ\text{C}$ 附近的局部凹凸。

2. 为什么平滑样条也很好：GCV 自动选择 $edf \approx 8.35$ ，与“用 LOOCV 选结点”的自由度相当，说明数据支持的“有效复杂度”大约就是 8-10 个参数；进一步增加结点（ $K > 10$ ）只会增大方差（见 p5_knot_selection.csv: $K=14$ 时 RSS 更小但 LOOCV/AIC 变差）。

3. BIC 更保守：BIC 的惩罚 $k \log n$ 较重（ $\log 364 \approx 5.9$ ），倾向选 $K=4$ （自然样条）或 $K=2$ ；

但它们的 LOOCV 明显更差。做预测时用 LOOCV/AIC 的复杂度更合适。




4. 曲线形状（对“温度对用电量的影响”的回答）：四种模型都给出 U 形（下凸）关系：

温度过低（ $< 15^\circ\text{C}$ ）或过高（ $> 25^\circ\text{C}$ ）时用电量最高， $25-30^\circ\text{C}$ 附近出现峰值 $\approx 3.7 \times 10^4$ 。



二次型的拟合曲线在左端的极小值出现在约 13°C （三次多项式）或数据左端点 8.6°C （样条），说明数据范围内用电量最低的区间大致是 $15-20^\circ\text{C}$ ；把最低点位置解释为“最舒适、耗电最少”的温度时要注意，样条给出的最小值落在数据边界附近，外推能力有限。

5. 残差诊断：所有模型的 Durbin-Watson 统计量都在 0.68-0.77 之间，远小于 2，


说明残差存在很强的正自相关（这是时间序列数据的典型现象：相邻日期的用电量受天气、节假日等共同因素影响）。因此：模型之间的比较（相同数据集、相同自相关结构）仍然有意义，但基于 i.i.d. 假设的标准误、置信区间和 AIC 惩罚都偏乐观，不宜过度解读小到 0.5% 的差异。若要认真建模，应该加入时间结构（AR 误差、季节哑变量等），这已超出本题范围。



结点个数与 BIC / LOOCV 的关系



平滑样条的 GCV 曲线与有效自由度



欠光滑与过光滑的对比

实现校核：自编的平滑样条与 `scipy.interpolate.make_smoothing_spline`（同一 GCV 准则）的 RSS 分别为 9.9645×10^8 与 9.9673×10^8 （相差 0.03%），两者一致。

Problem 6 (10 pts)：阿根廷各省经济指标的 PCA 回归

6.1 数据与标准化

`argentina.csv` 为 22 个省份的 10 个经济/社会指标。取 $y = \text{gdp}$ ，自变量为其余 9 个变量：`illiteracy`, `poverty`, `deficient_infra`, `school_dropout`, `no_healthcare`, `birth_mortal`, `pop`, `movie_theatres_per_cap`, `doctors_per_cap`。

这些变量量纲差异极大（`gdp` 量级 10^7 ，`movie_theatres_per_cap` 量级 10^{-6} ）。若直接对原始变量做 PCA，方差完全由量纲最大的变量主导：第一主成分就解释了 99.99999998% 的方差（见 `results/p6_pca_variance`），得到的主成分没有统计意义。因此必须先标准化（每个变量减均值、除标准差），即在相关矩阵上做 PCA。下文结果均指标准化后的 PCA。

6.2 前三个主成分及其解释的方差比例


主成分	特征值	方差解释比例	累计比例
PC1	4.545	0.4821	0.4821
PC2	1.237	0.1312	0.6133
PC3	1.053	0.1117	0.7250
PC4	0.918	0.0974	0.8223

前三个主成分累计解释 72.5% 的方差。（特征值之和为 $p \cdot n / (n - 1) = 9 \times 22 / 21 = 9.4286$ ，与非零特征值总和的检验一致；用 `numpy.linalg.eigvalsh` 独立计算相关矩阵特征值，与 `sklearn` 结果的最大偏差为 3.6×10^{-15} 。）

载荷（主成分方向，即标准化变量空间中的单位向量）：

变量	PC1	PC2	PC3
illiteracy	0.425	0.026	0.094
poverty	0.415	0.036	-0.156
deficient_infra	0.325	-0.286	-0.190
school_dropout	0.294	-0.047	0.584
no_healthcare	0.421	0.147	-0.007
birth_mortal	0.244	-0.409	0.478
pop	-0.101	0.680	0.312
movie_theatres_per_cap	-0.347	-0.512	0.044
doctors_per_cap	-0.297	-0.032	0.512

解释：PC1（48.2%）在 illiteracy、poverty、no_healthcare、deficient_infra 上载荷同号且较大，在 doctors_per_cap、movie_theatres_per_cap 上为负——这是一个“社会经济不利程度/贫困”综合指标；PC2（13.1%）主要对比 pop 与 movie_theatres_per_cap（大城市 vs 文娱设施密度），PC3（11.2%）由 school_dropout、birth_mortal、doctors_per_cap 主导，可粗略解释为“人口健康与教育”方向。



方差解释比例与主成分得分散点图

6.3 用前三个主成分回归

以 PC_1, PC_2, PC_3 为自变量（主成分得分）拟合 gdp ：


项	系数	标准误	t 值	p 值
截距	3.056e+07	7.92e+06	3.859	0.0011
PC1	-8.661e+06	3.80e+06	-2.278	0.0350
PC2	3.905e+07	7.29e+06	5.360	0.0001
PC3	1.981e+07	7.90e+06	2.509	0.0216

$R^2 = 0.6908$, $R^2_{adj} = 0.6393$, $F = 13.40$ ($p = 7.7 \times 10^{-5}$), $RSS = 2.482 \times 10^{16}$ 。三个主成分方向都在 5% 水平上显著：PC1 的负号说明“社会经济不利程度越高、gdp 越低”，PC2 的正号说明人口规模大（且文娱设施密度低）的省份 gdp 更高。等价地写成标准化 $\times$ 的系数 $\hat{\beta}_x = V\hat{\beta}_{PC}$ （ V 为载荷矩阵）：

变量	标准化尺度系数
illiteracy	-8.1e+05
poverty	-5.3e+06
deficient_infra	-1.8e+07
school_dropout	7.2e+06
no_healthcare	1.9e+06
birth_mortal	-8.6e+06
pop	3.4e+07
movie_theatres_per_cap	-1.6e+07
doctors_per_cap	1.1e+07

注记：前三个主成分只有 3 个自由度，却已经拿到 $R^2 = 0.69$ ；作为对照，用全部 9 个标准化变量做 OLS 得 $R^2 = 0.99396$ —— 说明 gdp 的变异还有相当一部分落在被丢弃的 6 个“小方差方向”上。这正是 PCA 回归的典型取舍：用 3 个自由度换取 72.5% 的自变量方差解释，适合预测/降维，但会遗漏个别变量特有的解释力（例如 pop 的方向只有 13% 的方差）。

稳健性对照：把因变量换成 $\log(\text{gdp})$ （gdp 右偏严重）， R^2 升到 0.7129 ($R^2_{\text{adj}} = 0.6651$)；不用标准化直接做 PCA 回归 R^2 可以到 0.9906，但这只是“量纲效应”而非真实结构，不能作为变量选择的依据。



载荷图与残差诊断

Problem 7 (10 pts)：小费数据的模型选择

7.1 数据与水平数

tip.csv（题目中写作 tips.csv）是餐厅消费记录， $n = 244$ 条。取 $Y = \text{tip}$ ， $A = \text{sex}$ （Male 157 / Female 87）， $B = \text{smoker}$ （No 151 / Yes 93）， $C = \text{time}$ （Dinner 176 / Lunch 68）。三个自变量都是二分类变量，水平数各为 2；day（星期几）本题不使用。

七个候选模型（参数个数 k 含截距）与最小二乘拟合结果：

模型	k	RSS	R^2	R^2_{adj}	AIC	BIC	ΔAIC	ΔBIC
M1: $Y \sim 1$	1	465.2125	0.0000	0.0000	159.46	162.96	0.00	0.00
M2: $Y \sim A+B+C$	4	456.3472	0.0191	0.0068	160.76	174.75	1.31	11.80

模型	k	RSS	R ²	R ² _{adj}	AIC	BIC	ΔAIC	ΔBIC
M3: Y ~ A+B+C+A:B	5	455.9913	0.0198	0.0034	162.57	180.06	3.12	17.10
M4: Y ~ A+B+C+B:C	5	455.9508	0.0199	0.0035	162.55	180.04	3.09	17.08
M5: Y ~ A+B+C+A:C	5	456.0608	0.0197	0.0033	162.61	180.10	3.15	17.14
M6: Y ~ A+B+C+A:B+B:C+A:C	7	455.4913	0.0209	-0.0039	166.31	190.79	6.85	27.83
M7: Y ~ A+B+C+A:B+B:C+A:C+A:B:C	8	454.4032	0.0232	-0.0057	167.72	195.70	8.26	32.74

其中 AIC 与 BIC 按常用的（相差一个常数不影响排序的）形式计算：

$$AIC = n \log \frac{RSS}{n} + 2k, \quad BIC = n \log \frac{RSS}{n} + k \log n.$$

M7 是“2×2×2 单元均值”饱和模型：它的最小二乘解就是 8 个单元各自的样本均值，故 RSS 等于组内平方和（数值校核：454.4032 与 454.4032，差 1.1×10^{-13} ）。八个单元的小费均值（括号内为样本数）见下表，可作为数据面貌的直观参考：

sex	smoker	time	均值	个数
Female	No	Dinner	3.044	29
Female	No	Lunch	2.460	25
Female	Yes	Dinner	2.949	23
Female	Yes	Lunch	2.891	10
Male	No	Dinner	3.158	77
Male	No	Lunch	2.942	20
Male	Yes	Dinner	3.123	47
Male	Yes	Lunch	2.791	13

7.2 三个准则选出的最佳模型

- R²_{adj} 最大：M2 (Y ~ A + B + C)，R²_{adj} = 0.0068；
- AIC 最小：M1（只有截距），AIC = 159.46；
- BIC 最小：M1（只有截距），BIC = 162.96。

为什么结论不同？三个准则的惩罚力度不同：

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n-1}{n-k}, \quad AIC \text{ penalty} = 2k, \quad BIC \text{ penalty} = k \log n (\approx 5.5k).$$


在这个数据里，从 M1 到 M2 增加 3 个参数只把 RSS 从 465.21 降到 456.35（降低 1.9%），换来的“信息量”很小：R²_{adj} 的惩罚较轻（该样本下 $\approx 1.2k$ ），于是 M2 略胜；而 AIC 的 2k 与 BIC 的 5.5k 都超过了这点收益，于是宁可选择最简单的 M1。从 M2 再往上加交互项，RSS 几乎不再下降（<0.2%），因此任何准则都不支持 M3 - M7，它们连 R²_{adj} 都变成了负数（说明这些参数完全是噪声）。

显著性检验（同一结论）：嵌套模型的 F 检验

比较	F	df	p 值
M1 → M2	1.554	3, 240	0.201
M2 → M3	0.187	1, 239	0.666
M2 → M6	0.149	3, 237	0.931
M6 → M7	0.565	1, 236	0.453

所有 p 值都大于 0.2：没有证据表明小费金额依赖于性别、是否吸烟或用餐时段。这与经典结论一致：《统计学习基础》中著名的 tips 例子 (Hastie 等, 图 3.7) 里, 真正对小费有解释力的是 total_bill, 而本题的候选变量里没有它, 所以“最好的模型”退化为只有截距也不奇怪。

结论表述: 若按题目要求分别回答, 则 R^2_{adj} 准则的最佳模型是 M2 ($Y \sim A + B + C$), AIC 与 BIC 准则的最佳模型是 M1 ($Y \sim 1$)。考虑到 F 检验不显著、 R^2_{adj} 只有 0.7%, 我们倾向于认为 M1 更可信, 即 A/B/C 三个因子对 tip 没有实际影响。



Problem 8 (15 pts): 学生表现数据的三种子集选择方法

8.1 数据说明与预处理

Student_Performance.csv: 因变量 $Y = \text{Performance Index}$ 。题目说明数据集含 1000 条记录, 但实际文件有 10000 行 (可能是题目笔误, 以下按实际的 $n = 10000$ 计算)。候选自变量 5 个: Hours Studied (HS)、Previous Scores (PS)、Extracurricular Activities (EA, 转成哑变量: Yes=1, No=0)、Sleep Hours (SH)、Sample Question Papers Practiced (SQ)。

选择准则取 AIC (同时给出 BIC 与 p 值准则作为对照, 以说明结论不依赖具体准则)。方法: FS (forward selection, 从空模型逐步加入使准则下降最多的变量)、BE (backward elimination, 从全模型逐步剔除使准则下降最多的变量)、FS+BE (stepwise, 每步先尝试加、再尝试删, 直到不再改进)。为了检查贪心算法是否真的找到全局最优, 还做了 $2^5 = 32$ 个全子集穷举。

8.2 结果

准则	方法	选中的变量	k	RSS	R ²	R ² _{adj}	AIC	BIC
AIC	FS	PS+HS+SH+SQ+EA	6	41513.51	0.9888	0.9887	14246.34	14289.60
AIC	BE	HS+PS+EA+SH+SQ	6	41513.51	0.9888	0.9887	14246.34	14289.60
AIC	FS+BE	PS+HS+SH+SQ+EA	6	41513.51	0.9888	0.9887	14246.34	14289.60
BIC	FS / BE / FS+BE	同上（5个变量全选）	6	41513.51	0.9888	0.9887	14246.34	14289.60

三种方法的选择路径（AIC 准则，括号内为该步骤后的 AIC）：

- FS：加入 PS（40939.13）→ HS（16520.02）→ SH（15177.47）→ SQ（14467.83）→ EA（14246.34），随后停止；
- BE：从全模型出发，删除任一变量都会使 AIC 变大，故直接停在全模型——即全模型被选中（与 FS 的终点一致）；
- FS+BE：路径与 FS 相同，且每步未发现可删的变量，故与 FS 结论一致。

全子集穷举：32 个模型里 AIC 与 BIC 的最小值都在 {HS, PS, EA, SH, SQ} 处取得，与三种贪心方法一致；p 值准则（ $\alpha = 0.05$ 逐步）同样保留全部 5 个变量。因此本题的结论非常稳健：没有变量需要被剔除。

8.3 最终模型与解释

最终模型（等价于全模型） $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 \text{HS} + \hat{\beta}_2 \text{PS} + \hat{\beta}_3 \text{SH} + \hat{\beta}_4 \text{SQ} + \hat{\beta}_5 \text{EA}$ ：

项	系数	标准误	t 值	p 值	95% 置信区间
截距	-34.076	0.127	-268.0	<1e-300	[-34.325, -33.826]
PS	1.0184	0.0012	866.5	<1e-300	[1.0161, 1.0207]
HS	2.8530	0.0079	362.4	<1e-300	[2.8375, 2.8684]
SH	0.4806	0.0120	40.0	<1e-300	[0.4570, 0.5041]
SQ	0.1938	0.0071	27.3	<1e-300	[0.1799, 0.2077]
EA	0.6129	0.0408	15.0	1.7e-50	[0.5330, 0.6928]


$R^2 = 0.9888$, $R^2_{\text{adj}} = 0.9887$, $\text{LOOCV} = 4.1564$ 。解释：在其他条件不变时，多做 1 小时学习提高 2.85 分，往年成绩每高 1 分提高 1.02 分，多睡 1 小时提高 0.48 分，多做 1 套样题提高 0.19 分，参加课外活动提高 0.61 分。

为什么“弱变量”也被保留？单变量回归的 R^2 与最终模型的显著性形成鲜明对照：


变量	单变量 R^2	单变量 AIC	最终模型中 p 值	最终模型系数
PS	0.8376	40939	<1e-300	1.0184
HS	0.1397	57610	<1e-300	2.8530
SH	0.0023	59091	<1e-300	0.4806
SQ	0.0019	59096	7.5e-158	0.1938
EA	0.0006	59108	1.7e-50	0.6129

SH、SQ、EA 单独看几乎没有解释力（ $R^2 \leq 0.003$ ），但在 5 个自变量近似正交（两两相关系数 $|r| < 0.02$ ）且 $n = 10^4$ 时，它们每一个的微小效应都能被精确估计出来，因此 AIC/BIC（以 $\log \text{RSS}$ 的信息量衡量）和 t 检验都会把它们留在模型里。这提醒我们：“统计显著”不等于“实际重要”（effect size），在报告模型时应该同时给出系数大小与 R^2 的边际增量。另外，AIC 准则下去掉

SH、SQ、EA 任意一个， ΔAIC 都小于 4，说明这些变量的取舍对预测影响很小——这也是模型选择本身存在不确定性的体现。



最终模型的残差诊断



各变量与因变量的关系（散点）

附录

A. 文件清单

文件	内容
code/common.py	公共工具：数据读取、OLS 计算（含 AIC/BIC/L00CV）、输出格式化
code/p1_p4_verify.py	题 1-4 的数值校核（恒等式、Monte Carlo、方差膨胀）
code/p5_power.py	题 5：四次拟合、结点选择、GCV 平滑样条与图
code/p6_argentina.py	题 6：标准化 PCA、主成分回归、系数回换算
code/p7_tips.py	题 7：7 个模型的 RSS/AIC/BIC 与嵌套 F 检验
code/p8_student.py	题 8：FS/BE/FS+BE、全子集穷举、诊断图
code/run_all.sh	一键复现全部结果
data/*.csv	题目数据（来自 hw1-2023-data.zip）
results/*.csv, *.md, *.json	全部数值结果与表格
figures/*.png	全部插图

B. 复现方式与环境

```
cd code && bash run_all.sh # 约 30 秒
```

使用的软件：Python 3.11, numpy 2.4, pandas 3.0, scipy 1.17, scikit-learn 1.9, statsmodels 0.15, matplotlib 3.11。所有随机模拟都固定了随机种子（`numpy.random.default_rng(20261008)`）。

C. 常用公式汇总

$$\text{AIC} = n \log \frac{\text{RSS}}{n} + 2k, \quad \text{BIC} = n \log \frac{\text{RSS}}{n} + k \log n, \quad \text{LOOCV} = \frac{1}{n} \sum_i \left(\frac{e_i}{1 - h_{ii}} \right)^2, \quad R_{\text{adj}}^2 = 1 - \frac{\text{RSS}/(n-k)}{\text{TSS}/(n-1)}.$$