

Assignment 1

Due at 22:00 on Thursday, October 8

Total is 100 points

Problem 1. (15 pts) 对于样本 $(x_1, y_1), \dots, (x_n, y_n)$ 使用最小二乘法得到估计 $\hat{\beta}_0, \hat{\beta}_1$. 假设拟合值为 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$. 试证明以下结论:

1. $\sum_{i=1}^n \hat{y}_i / n = \bar{y}$.
2. $\text{SSreg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$.
3. $R^2 = r_{XY}^2$, 其中 $r_{XY}^2 = \text{SXY}^2 / (\text{SXX} \cdot \text{SYY})$.

Problem 2. (10 pts) 假设有一个没有截距的线性模型

$$y_i = \beta^* x_i + e_i, \quad i = 1, \dots, n,$$

其中 $e_1, \dots, e_n$ 为i.i.d. $N(0, \sigma_*^2)$ 的随机变量. 考虑 β^* 的最小二乘估计量 $\hat{\beta}$ (最小二乘法中也不考虑截距), 以及另一个估计量 $\tilde{\beta} = \bar{y} / \bar{x}$.

1. 证明 $\hat{\beta}$ 与 $\tilde{\beta}$ 均为 β^* 的无偏估计.
2. 试比较 $\hat{\beta}$ 与 $\tilde{\beta}$ 哪个方差更小.

Problem 3. (10 pts) (欠拟合, underfitting) 考虑一个线性模型

$$y_i = \beta_0^* + \beta_1^* x_{i1} + \dots + \beta_p^* x_{ip} + e_i, \quad 1 \leq i \leq n,$$

或者等价地写为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta}^* + \mathbf{e}.$$

由于不知道以上的真实模型, 我们在做线性回归时可能会漏掉一些变量. 不失一般性, 假定在所有 $p+1$ 个变量中 (包括 β_0 对应的变量常数1) 我们采用了前 p_1 个变量, 而忽略了后 $p_2 = p+1 - p_1$ 个变量. 令

$$\mathbf{X}_1 = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1(p_1-1)} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & \cdots & x_{n(p_1-1)} \end{bmatrix}, \quad \mathbf{X}_2 = \begin{bmatrix} x_{1p_1} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots \\ x_{np_1} & \cdots & x_{np} \end{bmatrix},$$

它们分别代表了前 p_1 个变量和后 p_2 个变量的样本值, 那么 $\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2]$. 同时, 令

$$\boldsymbol{\beta}_1^* = \begin{bmatrix} \beta_0^* \\ \beta_1^* \\ \vdots \\ \beta_{p_1-1}^* \end{bmatrix}, \quad \boldsymbol{\beta}_2^* = \begin{bmatrix} \beta_{p_1}^* \\ \vdots \\ \beta_p^* \end{bmatrix},$$

那么原模型可以等价地表示为

$$\mathbf{Y} = \mathbf{X}_1 \boldsymbol{\beta}_1^* + \mathbf{X}_2 \boldsymbol{\beta}_2^* + \mathbf{e}.$$

1. 按照我们对变量的选择, 最小二乘的目标为最小化

$$\|\mathbf{Y} - \mathbf{X}_1 \boldsymbol{\beta}_1\|^2$$

试计算由此得到的一个 $\boldsymbol{\beta}_1^*$ 的估计量 $\tilde{\boldsymbol{\beta}}_1$.

2. 试证明, 当且仅当 $\mathbf{X}_1^\top \mathbf{X}_2 = \mathbf{0}$ 时, $\tilde{\boldsymbol{\beta}}_1$ 为 $\boldsymbol{\beta}_1^*$ 的无偏估计量。(提示: 将 $\mathbf{Y} = \mathbf{X}_1 \boldsymbol{\beta}_1^* + \mathbf{X}_2 \boldsymbol{\beta}_2^* + \mathbf{e}$ 代入1的结果中, 再求期望。)

Problem 4. (10 pts) (过拟合, overfitting) 考虑一个线性模型

$$\mathbf{Y} = \mathbf{X} \boldsymbol{\beta}^* + \mathbf{e}.$$

由于不知道以上的真实模型, 我们在做线性回归时可能会加入一些无关变量。假设我们加入了另外的 q 个变量, 它们的样本值为

$$\mathbf{X}' = \begin{bmatrix} x_{1(p+1)} & \cdots & x_{1(p+q)} \\ \vdots & \vdots & \vdots \\ x_{n(p+1)} & \cdots & x_{n(p+q)} \end{bmatrix}.$$

我们让

$$\mathbf{Z} = [\mathbf{X} \quad \mathbf{X}'],$$

即把所有 $p + q + 1$ 个变量都放进来, 形成一个 $n \times (p + q + 1)$ 的矩阵。同时在 $\boldsymbol{\beta}^*$ 后面加入 q 个0, 得到 $\mathbf{b}^* = (\beta_0^*, \beta_1^*, \dots, \beta_p^*, 0, \dots, 0)^\top$. 那么原模型可以等价地表示为

$$\mathbf{Y} = \mathbf{Z} \mathbf{b}^* + \mathbf{e}.$$

1. 按照我们对变量的选择, 最小二乘的目标为最小化

$$\|\mathbf{Y} - \mathbf{Z} \mathbf{b}\|^2$$

试计算由此得到的一个 $\mathbf{b}^*$ 的估计量 $\tilde{\mathbf{b}}$.

2. 让 $\tilde{\boldsymbol{\beta}}$ 为 $\tilde{\mathbf{b}}$ 的前 $p+1$ 个分量组成的向量, 试证明 $\tilde{\boldsymbol{\beta}}$ 为 $\boldsymbol{\beta}^*$ 的无偏估计量。(提示: 将 $\mathbf{Y} = \mathbf{Z}\mathbf{b}^* + \mathbf{e}$ 代入1的结果中, 再求期望。)

Problem 5. (20 pts) powerconsumption.csv 收集了摩洛哥三个地区的2017年各个时刻的用电量, Date是日期, Temperature是当天的温度。我们想知道平均温度对于用电量的影响。

取PowerConsumption_Zone1为因变量, Temperature为自变量, 用三次多项式、三次样条、自然三次样条、平滑样条分别拟合数据, 并比较它们的效果。对于三次样条与自然三次样条, 可以自行取合理的结点。

Problem 6. (10 pts). argentina.csv 收集了阿根廷每个省份收集的十项经济和社会指标。我们希望用其余变量(不含province变量)来预测gdp变量。

1. 找出自变量的前三个主成分, 计算这三个主成分能解释的方差比例。
2. 将前三个主成分作为新的自变量, 拟合一个线性模型。

Problem 7. (10 pts). tips.csv 包含了有关餐厅顾客的各种属性的信息, 包括总消费金额、小费金额、性别、顾客是否吸烟、星期几、一天中的时间以及聚餐人数等。我们取tip为因变量Y, sex, smoker和time为自变量A,B,C。考虑以下模型:

$Y \sim 1$ (只有截距的模型)
$Y \sim A + B + C$
$Y \sim A + B + C + A:B$
$Y \sim A + B + C + B:C$
$Y \sim A + B + C + A:C$
$Y \sim A + B + C + A:B + B:C + A:C$
$Y \sim A + B + C + A:B + B:C + A:C + A:B:C$

1. 统计出A,B,C的类别(level)数, 样本数, 并计算RSS。
2. 试分别选用 R^2_{adj} , AIC与BIC作为模型选择准则, 选出最佳模型。

Problem 8. (15 pts). Student Performance.csv 是一个旨在探究影响学生学业表现因素的数据库。该数据集包含 1000 条学生记录, 每条记录都包含了关于各种预测因素以及表现指标的信息。记学生的表现 (Performance Index) 为因变量Y, 记剩余变量为自变量。自选一个指标, 分别用FS, BE和FS+BE三种方法选出最好的模型。(注意将Extracurricular Activities处理成虚拟变量)