Assignment 2

Due at 22:00 on Thursday, October 29

Total is 140 points

Problem 1. (10 pts) 在一个回归问题中，$n = 5$、$p = 2$，$\bar{x}_1 = 2$、$\bar{x}_2 = -1$、$\bar{y} = 3$。中心化后的数据为

$$X = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 0 & 0 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}, \qquad Y = \begin{pmatrix} 3 \\ -4 \\ 1 \\ 2 \\ -2 \end{pmatrix}.$$

本题不再标准化 X，截距不受惩罚。定义

$$\hat{\beta}^{\mathrm{OLS}} = \arg\min_{\beta} \tfrac{1}{2}\|Y - X\beta\|_2^2, \quad \hat{\beta}^{\mathrm{ridge}} = \arg\min_{\beta} \left\{ \tfrac{1}{2}\|Y - X\beta\|_2^2 + \tfrac{\lambda}{2}\|\beta\|_2^2 \right\},$$

$$\hat{\beta}^{\mathrm{lasso}} = \arg\min_{\beta} \left\{ \tfrac{1}{2}\|Y - X\beta\|_2^2 + \lambda\|\beta\|_1 \right\}.$$

1. 取 $\lambda = 5$，手算三种方法的斜率，并用 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}_1 - \hat{\beta}_2\bar{x}_2$ 恢复截距。写清计算过程。

2. 结合结果说明岭回归与 lasso 在系数收缩及变量选择上的差异。

Problem 2. (20 pts) 使用 `ais.csv`，因变量与十个候选自变量同第6题。将 `Sex` 编码为0/1虚拟变量。配套 `ais_split.csv` 的 `row_id` 对应原始数据行号，`set` 指定150条训练记录及52条测试记录，`fold` 指定训练集中的五折划分。

岭回归与 lasso 均使用 `glmnet` 的高斯模型（分别取 `alpha=0` 和 `alpha=1`），按同一 `fold` 进行五折 CV，用验证 MSE 选择 `lambda.min`。令 `standardize=TRUE`，保留不受惩罚的截距；不手动标准化因变量。其目标函数约定为

$$\frac{1}{2n_{\mathrm{tr}}} \sum_{i \in \mathrm{tr}} (y_i - \beta_0 - x_i^{\top}\beta)^2 + \lambda \left\{ \frac{1-\alpha}{2}\|\beta\|_2^2 + \alpha\|\beta\|_1 \right\},$$

其中惩罚作用于标准化后的自变量系数；此处 λ 的尺度与第7题不同。

1. 拟合岭回归，绘制 CV 误差曲线，报告选定的 λ、原始量纲上的系数与测试 MSE。 (6 pts)

2. 拟合 lasso，报告同样结果及非零斜率的个数。比较两种方法的测试误差。 (6 pts)

3. 在原始量纲上组合两种方法的预测：

$$\hat{y}_i^{\text{combo}}(\omega) = \omega \hat{y}_i^{\text{ridge}} + (1-\omega)\hat{y}_i^{\text{lasso}}, \quad \omega = 0, 0.1, \ldots, 1.$$

绘制测试 MSE 随 ω 的变化并描述结果；说明该曲线的最小值为何不能作为经独立测试验证的调参结果。若需要选择 ω，应在哪个数据集上进行？ (8 pts)

Problem 3. (20 pts) 自学 group lasso，并用于 `ais.csv`。使用与第8题相同的因变量、训练/测试划分及五折编号，将十个自变量按以下顺序排列并分组：

组别	自变量	含义
1	`Ht, Wt, BMI`	身体尺寸
2	`RCC, Hc, Hg`	红细胞相关指标
3	`WCC, Ferr`	其他血液指标
4	`SSF`	皮褶厚度
5	`Sex`	性别（0/1）

即 `groupid=c(1,1,1,2,2,2,3,3,4,5)`。请用训练集的均值及样本标准差标准化每一列（包括 `Sex`），并将同一变换应用于测试集。因变量保持原始量纲，截距不受惩罚，组惩罚权重取各组大小的平方根。按此训练集变换后的设计矩阵进行五折 CV；测试集不参与任何参数选择。

可使用 R 包 `gglasso`（以下示例按1.6版，`L2` 对应均方误差）：

```
cv.gglasso(x, y, group=groupid, loss="ls",
  pred.loss="L2", foldid=foldid, nfolds=5)
gglasso(x, y, group=groupid, loss="ls", lambda=lambda)
predict(object, newx=x.test)
```

请报告软件包版本；使用其他版本时核对 `pred.loss` 的实际定义，确认用于调参的是平方预测误差；也可自行实现五折 MSE 验证。

1. 绘制 CV 误差曲线，用最小 CV MSE 选择 λ，报告截距、标准化量纲上的系数及保留的组。(12 pts)
2. 计算测试 MSE，与第8题比较；说明 group lasso 的组选择与普通 lasso 的变量选择有何不同。(8 pts)

参考：`https://cran.r-project.org/web/packages/gglasso/gglasso.pdf`。

Problem 4. (10 pts) Exercise 9.10 in Weisberg.

Problem 5. (10 pts) Exercise 9.16 in Weisberg.

Problem 6. (20 pts) 数据"data.csv"中包含了一个因变量Y和三个自变量X_1, X_2, X_3的3000个样本. 我们先拟合一个线性模型$\log Y \sim X_1 + X_2 + X_3 + X_3^2$.

1. 对拟合出的模型通过画残差图和统计检验两种方法判断同方差性。

2. 对拟合出的模型通过画残差图和统计检验两种方法判断正态性。

3. 重新拟合一个$(\log Y)^2 \sim X_1 + X_2 + X_3 + X_3^2$的模型，判断同方差性与正态性是否得到改善。

Problem 7. (10 pts) 对于讲义中的"money.RData"数据，试通过某种方法修正自相关性。

Problem 8. (10 pts) 假设随机效应模型

$$y_{it} = \beta_0^* + \mu_i + \mathbf{x}_{it}^\top \mathbf{b}^* + e_{it}, \quad 1 \le i \le n, 1 \le t \le T, \tag{1}$$

其中$\mathrm{E}(\mu_i \mid \mathbf{x}_{it}) = 0$, $\mathrm{Var}(\mu_i \mid \mathbf{x}_{it}) = \sigma_\mu^2$, $\mathrm{E}(e_{it} \mid \mathbf{x}_{it}) = 0$, $\mathrm{Var}(e_{it} \mid \mathbf{x}_{it}) = \sigma_*^2$, 所有$\mu_i$与所有$e_{it}$都互相独立.

我们将μ_i与e_{it}合并得到$u_{it} = \mu_i + e_{it}$. 令$\psi = \sigma_*^2/(\sigma_*^2 + T\sigma_\mu^2)$, $\theta = 1 - \sqrt{\psi}$. 为了去除u_{it}与u_{is}之间的相关性，我们采用一个"准去均值法"，即让$\bar{y}_i = \sum_{t=1}^T y_{it}/T$, $\bar{\mathbf{x}}_i = \sum_{t=1}^T \mathbf{x}_{it}/T$, 再让

$$\tilde{y}_{it} = y_{it} - \theta \bar{y}_i,$$
$$\tilde{\mathbf{x}}_{it} = \mathbf{x}_{it} - \theta \bar{\mathbf{x}}_i.$$

于是模型(1)可以重新写成

$$\tilde{y}_{it} = \beta_0^* + \tilde{\mathbf{x}}_{it}^\top \mathbf{b}^* + \tilde{u}_{it}, \quad 1 \le i \le n, 1 \le t \le T, \tag{2}$$

其中$\tilde{u}_{it} = u_{it} - \theta \bar{u}_i$, $\bar{u}_i = \sum_{t=1}^T u_{it}/T$.

1. 证明：$\mathrm{Var}(\tilde{u}_{it}) = \sigma_*^2$.

2. 证明：对于$t \neq s$, $\mathrm{Cov}(\tilde{u}_{it}, \tilde{u}_{it}) = 0$,

以上结论说明，用"准去均值法"可以令模型的随机误差重新变成不相关的。由此处理后的数据就可以用OLS来估计。

Problem 9. (30 pts) Grunfeld数据包含了10家大型制造业公司的一些基本指标。在R中运行

```
install.packages("plm")
library(plm)
data(Grunfeld)
```

可以获取此数据。其变量含义如下：

- inv: 投资额（投资支出）
- value: 公司市值

- capital: 资本存量（厂房、设备）
- firm: 公司ID
- year: 年份

我们采用inv作为因变量，value, capital作为两个自变量。

1. 分别拟合固定效应模型、随机效应模型、混合回归模型。
2. 解释每个模型中估计出的回归系数的含义。
3. 用适当的检验决定使用哪个模型。